

Порядок работы

- 1) Сформировать датасеты с помощью программы из 1 лабораторной прошлого семестра разных величин (малый ~ 1000-10000, средний~ 20000-75000, большой~ 100000-250000)
- 2) Вычислить среднее значение, значение медианы и моды, построить распределение
- 3) Удалить в столбцах 3, 5, 10, 20, 30 % значений, притом делать это выбросами.
- 4) Выполнить заполнение пропусков методами.
- 5) Оценить результаты: вычислить среднее значение, значение медианы и моды, построить распределение.
- 6) Сделать выводы.

Методы заполнения пропусков

- 1) Удаление строк с пустыми значениями - Анализ полных наблюдений
- 2) Попарное удаление
- 3) Хот-Дек
- 4) Метод подстановки с подбором внутри групп.
- 5) Метод заполнения средним значением
- 6) Метод заполнения значением медианы
- 7) Метод заполнения моды
- 8) Повторение результата последнего наблюдения перед пропуском
- 9) Заполнение пропусков на основе линейной регрессии
- 10) Заполнение пропусков на основе стохастической линейной регрессии
- 11) Метод восстановления пропущенного значения сплайн-интерполяцией по присутствующим элементам
- 12) Метод восстановления пропущенного значения на основе Zet-алгоритма

Методика выбора наиболее эффективного алгоритма

Эффективность того или иного метода устанавливается экспериментально в такой последовательности:

- 1) формируется массив комплектных записей. Для этого неполные наблюдения исключаются из рассмотрения;
- 2) «искусственно» создаются пропущенные значения, т. е. в таблице удаляются некоторые элементы $a_1, \dots, a_n$;
- 3) пропущенные значения поочередно предсказываются с использованием разных методов $M_1, \dots, M_k$;
- 4) рассчитываются суммарные относительные погрешности для каждого метода:

$$\Delta_{M_j} = \sum_{i=1}^n \frac{|a_i - \bar{a}_i|}{a_i} \cdot 100 \%,$$

где j — номер метода, $j = 1, \dots, k$; a_i — пропущенное значение; $\bar{a}_i$ - предсказанное значение.

Метод, для которого суммарная относительная погрешность будет минимальной, будет наиболее эффективным.

Поскольку набор методов заполнения пропусков достаточно велик, то тестировать можно те методы, которые реализованы в пакете обработки данных, используемом исследователем, поскольку проверка эффективности алгоритмов данных без применения программного обеспечения — трудоемкая задача.

Сравнение эффективности алгоритмов

Процесс сравнения эффективности алгоритмов, можно организовать следующим образом:

- 1) сформировать датасет, состоящий только из полных наблюдений;
- 2) оценить на нем параметры распределений переменных и осуществить интересующие виды анализа. Полученные только на полных наблюдениях результаты станут эталоном – базой для дальнейших сравнений;
- 3) внести в датасет полных наблюдений различное количество случайных пропусков. В итоге получится совокупность массивов данных разной степени полноты;
- 4) на каждом из них повторить шаг 2 и оценить смещения в оценках, возникшие в результате наличия в данных разного количества пропусков;
- 5) заполнить в каждом датасете пропуски с использованием нескольких сравниваемых методов заполнения пропусков. Повторить на каждом полном массиве шаг 2.
- 6) сравнить полученные при использовании каждого из методов заполнения пропусков результаты с эталонными результатами, полученными на шаге 2.
- 7) выбрать для каждой ситуации наиболее эффективный метод заполнения пропусков и отразить их в отчете.